AI具身智能

一.核心问题

“如何解决具身智能的端到端延迟问题”，具身智能区别于传统AI的关键在于实时物理交互，而端到端延迟直接决定系统是否可用、是否安全。
相关文献：
[文献1] 明确指出部署具身系统面临 **"prolonged runtime latency"（长时间运行时延迟）** 的挑战，发现随着智能体数量增加，**成功率急剧下降、协作效率降低**。
[文献2]([2510.17111] Efficient Vision-Language-Action Models for Embodied Manipulation: A Systematic Survey)- 明确指出VLA模型的**巨大计算和内存需求**与边缘平台的实时性要求**存在根本冲突**,将"reducing latency"作为效率优化的核心目标之一,系统梳理了为解决延迟问题而提出的各类方法

二.技术分类

2.1 计算卸载类

核心思路：延迟主要来自云端推理，通过将计算任务从云端下沉到边缘或端侧，减少传输和排队延迟。

2.1.1 边端协同和动态任务卸载

[文献3](Splitwise: Collaborative Edge-Cloud Inference for LLMs via Lyapunov-Assisted DRL - PULRC Portal)将Transformer层细粒度分割到注意力头和FFN子块，比按层分割提供更多分区选择；用分层DRP策略+Lyapunov优化联合优化延迟、能耗和精度。结果：在Jetson Orin NX等设备上，端到端延迟降低**1.4倍-2.8倍**，95分位延迟比云-only降低**53%-61%**

[文献4](Game-Based Adaptive FLOPs and Partition Point Decision Mechanism With Latency and Energy-Efficient Tradeoff for Edge Intelligence | IEEE Journals & Magazine | IEEE Xplore)离线分区方法无法适应动态计算环境，且在线学习方法存在反馈延迟，提出了基于博弈论的自适应FLOPs分配和分区点决策，在动态环境中同时降低延迟并提高能效,在机器人边缘智能系统上验证了有效性。

2.1.2 端侧模型压缩与加速

[文献5]([2510.17111] Efficient Vision-Language-Action Models for Embodied Manipulation: A Systematic Survey)这是一篇这方面的综述，它总结了在模型架构维度上怎么压缩模型，加速信息传递和计算过程，他总结的方法如下：
量化（Quantization）：INT8/FP8量化降低推理延迟
知识蒸馏（Knowledge Distillation）：将大模型知识迁移到小模型
结构化剪枝（Structured Pruning）：移除冗余结构
神经网络架构搜索（NAS）：自动设计轻量化架构
紧凑架构设计：如TinyVLA、SmolVLA等专门为低延迟设计的小型VLA

[文献6]([PDF] Efficient Vision-Language-Action Models for Embodied Manipulation: A Systematic Survey | Semantic Scholar):引入异步推理栈，将感知和动作预测与动作执行解耦

2.2 通信优化类

核心思路：即使计算在边缘/云端，通过优化通信环节减少传输延迟和不确定性。

2.2.1 语义通信

[文献7]([2312.13182] Goal-oriented Semantic Communications for Robotic Waypoint Transmission: The Value and Age of Information Approach)提出任务导向和语义感知的机器人控制通信框架（TSRC），利用数据上下文及其在任务中的重要性，技术对发射端和接收端都做了优化，发射端：DRL生成最优控制指令 + 主动重传方案（DeepPro），接收端：基于VoI（信息价值）和AoI（信息年龄）的队列重排机制（VA-QOM）

2.2.2 5G\6G URLLC

[文献7]指出：5G URLLC难以支撑安全机器人操作，6G需要提供“hyper-reliable and low-latency communication”才能实现更安全的机器人控制。

2.3 模型设计与架构

核心思路：重新设计模型架构，突破“先感知、后决策、再执行”的串行限制。

[文献8]([2510.17111] Efficient Vision-Language-Action Models for Embodied Manipulation: A Systematic Survey)一篇现有综述，总结了模型设计与架构的优化。

- **扩散模型加速**：DDIM、LCM等技术减少去噪步数
- **自回归模型并行解码**：打破串行生成瓶颈
- **异步推理架构**：如VLASH框架，实现流畅、准确、快速的反应控制
- **分层混合架构**：大模型负责高层规划（低频），轻量控制器负责底层执行（高频）

三. 未来方向

3.1面向具身智能的“通信-计算-控制”一体化设计

核心问题

现有研究大多将通信、计算、控制视为**串行环节**独立优化，导致：

- 通信优化只关注传输延迟，忽略计算负载变化
- 计算卸载只关注推理延迟，忽略信道质量波动
- 控制律设计假设通信是理想的，无法适应真实网络

研究方向

1. **端到端延迟的联合建模与优化**

- 建立包含感知采样、传输、计算、执行的全链路延迟模型
- 基于多目标优化（延迟+能耗+精度+稳定性）的协同调度算法
- 将通信信道状态、边缘服务器负载、机器人运动状态纳入统一优化空间

2. **基于学习的联合资源分配**
   - 用多智能体强化学习（MARL）同时优化通信资源（频谱、功率）和计算资源（模型分割点、卸载决策）
   - 借鉴Splitwise的细粒度分割思想，在Transformer层内部实现通信-计算的流水线并行
3. **延迟感知的控制与通信协同设计**
   - 将通信延迟的统计分布（而非平均值）纳入控制器设计
   - 设计“控制-通信”联合编码，根据控制误差动态调整通信策略

3.2 实时推理架构

核心问题

VLA等大模型带来强大的泛化能力，但推理延迟（秒级）与实时控制需求（毫秒级）存在**根本矛盾**：

- 现有加速方法（量化、剪枝）精度损失明显
- 扩散模型去噪步数多，难以达到实时
- 异步推理框架（如VLASH）仅适用于特定任务类型

研究方向

1. **面向具身的模型架构创新**
   - 设计“原生低延迟”的VLA架构，而非对现有大模型做后处理压缩
   - 探索**线性复杂度**的注意力机制（如Mamba、RWKV）在具身任务中的适用性
   - 开发**稀疏激活**的专家混合模型（MoE），实现按需计算
2. **推理-执行流水线并行**
   - 将推理过程拆分为“粗粒度规划”与“细粒度执行”，实现流水线重叠
   - 借鉴扩散模型的**渐进式解码**思想，边推理边输出动作，不等全量完成
3. **模型轻量化与硬件协同设计**
   - 针对机器人端侧芯片（如Jetson、RP2040）的**架构-算法协同设计**
   - 探索**存内计算**（Computing-in-Memory）在具身场景的应用

3.3 网络控制系统具身化与物理信息融合

核心问题

网络化控制系统（NCS）理论已有数十年积累，但**未充分考虑具身智能的新特性**：

- 传统NCS假设系统动力学已知，而具身系统常面临未知/非结构化环境
- 现有研究多关注线性系统，而机器人本质是非线性的
- 缺乏将**感知不确定性**与**通信不确定性**统一建模的框架

研究方向

1. **感知-通信-控制的不确定性统一建模**
   - 将感知噪声、通信丢包/延迟、执行器噪声统一建模为“信息不确定性”
   - 基于**概率控制**（如模型预测控制MPC with probabilistic constraints）设计鲁棒控制器
2. **学习增强的网络化控制**
   - 利用高斯过程等非参数模型在线学习环境动力学和延迟分布
   - 结合强化学习，实现**自适应的延迟补偿策略**
3. **事件触发控制的具身化扩展**
   - 设计基于“控制误差”和“通信成本”的事件触发机制，而非固定周期传输
   - 将机器人运动状态（如速度、加速度）纳入事件触发条件
4. **数字孪生与网络化控制的闭环**
   - 构建机器人的数字孪生模型，在网络中断期间继续模拟运行
   - 利用孪生模型预测未来状态，提前调整控制指令