纲举目张

LMCache: An Efficient KV Cache Layer for Enterprise-Scale LLM Inference	arXiv	2025	此处为语雀内容卡片，点击链接查看：https://www.yuque.com/linlin-sami1/sm6gb7/qf5f55apfkwg0bp3?view=doc_embed	LMCache 建立了业界首个开源的高性能分布式 KV Cache 管理层，通过解耦推理引擎与存储后端，引入分块批处理 (Batched Operations) 和计算与 I/O 流水线化 (Compute-I/O Overlapping) 等优化机制，在保障兼容性的前提下实现了跨查询、跨引擎的缓存复用与传输，使大模型推理吞吐量提升高达 15 倍并显著降低首字延迟 (TTFT)。
Maximizing KV-Cache Reuse While Minimizing Network Latency in Cross-Region LLM Load Balancing	arXiv	2026	此处为语雀内容卡片，点击链接查看：https://www.yuque.com/linlin-sami1/sm6gb7/vbo8puu9miqiq3ty?view=doc_embed	GORGO 提出了一种全新的负载均衡框架，通过建立联合优化模型，显式权衡了 Key-Value (KV) Cache 的重用收益、广域网 (WAN) 传输延迟以及推理节点的实时队列状态，从而在地理分布式的 LLM 服务场景中，将中位数首字延迟 (TTFT) 显著降低了 2.5 倍。
MOONCAKE: Trading More Storage for Less Computation — A KVCache-centric Architecture for Serving LLM Chatbot	FAST	2025	此处为语雀内容卡片，点击链接查看：https://www.yuque.com/linlin-sami1/sm6gb7/rar64dg3y86u5gnx?view=doc_embed	MOONCAKE 是月之暗面 (Moonshot AI) 为其 Kimi 助手开发的高性能推理平台，它通过创新的“以存储换计算”策略，利用 GPU 集群中未充分利用的 CPU、DRAM 和 SSD 资源构建了 PB 级的分布式 KVCache 存储池，通过物理分离预填充 (Prefill) 与解码 (Decoding) 阶段并结合感知缓存的全局调度，在满足严苛延迟 SLO 的前提下，将长文本场景的请求处理容量提升了 59% 至 498%。

BanaServe: Unified KV Cache and Dynamic Module Migration for Balancing Disaggregated LLM Serving in AI Infrastructure	arXiv	2025	此处为语雀内容卡片，点击链接查看：https://www.yuque.com/linlin-sami1/sm6gb7/tzelxazzlkvtxwiv?view=doc_embed	BanaServe 通过引入层级权重迁移、注意力级 KV Cache 迁移以及具备层级重叠传输功能的全局 KV 缓存存储 (Global KV Cache Store)，彻底解耦了大语言模型推理中的资源分配与状态放置，从而消除了解耦架构中固有的负载失衡与缓存诱导的热点问题，显著提升了吞吐量并降低了延迟 。
vLLM: Efficient Memory Management for Large Language Model Serving with PagedAttention	SOSP	2023	此处为语雀内容卡片，点击链接查看：https://www.yuque.com/linlin-sami1/sm6gb7/rxykc34gkfdk7nqp?view=doc_embed	该研究借鉴操作系统中经典的虚拟内存分页思想，提出了 PagedAttention 算法及 vLLM 推理引擎，通过将逻辑连续的键值缓存 (KV Cache) 映射到非连续的物理显存块，彻底消除了显存内部与外部碎片，并在不影响延迟的前提下，将主流大语言模型在各种解码算法下的服务吞吐量提升了 2 至 4 倍 。
SkyWalker：A Locality-Aware Cross-Region Load Balancer for LLM Inference	EuroSys	2026	此处为语雀内容卡片，点击链接查看：https://www.yuque.com/linlin-sami1/sm6gb7/zqfndvu47ek2wl63?view=doc_embed	SkyWalker 是一套针对大规模多区域大语言模型 (LLM) 推理设计的分布式负载均衡系统，它通过两层式跨区域调度架构有效聚合了全球流量的昼夜波动模式 (Diurnal Patterns)，结合前缀感知 (Prefix-aware) 路由与基于待处理请求 (Pending Requests) 的选择性推送 (Selective Pushing) 机制，在保持低延迟与高 KV-Cache 局部性的前提下，成功实现了 1.12-2.06 倍的吞吐量提升及 25% 的运营成本缩减。

OPTINIC: A Resilient and Tail-Optimal RDMA NIC for Distributed ML Workloads	arXiv	2025	此处为语雀内容卡片，点击链接查看：https://www.yuque.com/linlin-sami1/sm6gb7/mu4xf2szpm6kv2ht?view=doc_embed	OPTINIC 是一种专为分布式机器学习 (ML) 设计的领域特定 (Domain-specific) RDMA 传输协议，它通过消除网卡硬件中的重传和按序交付机制，引入基于自适应超时 (Adaptive Timeouts) 的有界完成语义，并结合软件层的数据恢复技术，在显著简化硬件复杂度的同时，将训练精度达标时间 (TTA) 缩短了 2 倍，并降低了 3.5 倍的尾部延迟。
DualPath: Breaking the Storage Bandwidth Bottleneck in Agentic LLM Inference	arXiv	2026	此处为语雀内容卡片，点击链接查看：https://www.yuque.com/linlin-sami1/sm6gb7/swtb8d5vu8651xnb?view=doc_embed	针对多轮交互的智能体 (Agentic) 工作负载中 KV-Cache 加载导致的存储 I/O 瓶颈，DualPath 提出了一种创新的双路径加载架构，通过利用 Decode 引擎闲置的存储带宽并通过计算网络进行 RDMA 转发，成功将离线推理吞吐量提升至 1.87 倍，在线服务能力提升至 1.96 倍 。
ServerlessLLM: Low-Latency Serverless Inference for Large Language Models	OSDI	2024	此处为语雀内容卡片，点击链接查看：https://www.yuque.com/linlin-sami1/sm6gb7/fyeqgukoq2gxt4ge?view=doc_embed	ServerlessLLM 通过创新性地利用 GPU 服务器本地的多级存储层次结构，并结合优化的模型存储格式、基于令牌序列的实时推理迁移机制以及启动时间最优的模型调度算法，从根本上解决了大规模语言模型在无服务器架构中由于权重文件过大而导致的分钟级冷启动瓶颈，实现了相比现有系统 10 到 200 倍的首字延迟优化。

Llumnix: Dynamic Scheduling for Large Language Model Serving	OSDI	2024	此处为语雀内容卡片，点击链接查看：https://www.yuque.com/linlin-sami1/sm6gb7/kka3dlyg7qctcbqn?view=doc_embed	Llumnix 解决了大规模语言模型推理中由于请求异构性和执行不可预测性导致的性能瓶颈，通过引入类似于 OS 上下文切换的请求级在线迁移机制和基于“虚拟负载（Virtual Usage）”的统一调度策略，在保证极低迁移开销的前提下，将尾部延迟（Tail Latency）降低了一个数量级，并实现了高达 36% 的资源成本节约。
SpotServe: Serving Generative Large Language Models on Preemptible Instances	ASPLOS	2024	此处为语雀内容卡片，点击链接查看：https://www.yuque.com/linlin-sami1/sm6gb7/ycnosvd017x0wz30?view=doc_embed	SpotServe 是业界首个专为云端抢占式实例设计的分布式 LLM 推理系统，通过动态重并行化配置、基于 Kuhn-Munkres 算法的轻量级上下文迁移和令牌级 (Token-level) 有状态恢复机制，在保障服务等级目标 (SLO) 的前提下，相比按需实例节省了高达 54% 的货币成本，并将长尾延迟降低了 2.4 至 9.1 倍。
CacheGen: KV Cache Compression and Streaming for Fast Large Language Model Serving	SIGCOMM	2024	此处为语雀内容卡片，点击链接查看：https://www.yuque.com/linlin-sami1/sm6gb7/oi0d63eb66dnzqvg?view=doc_embed	CacheGen 是一个高速上下文加载模块，它通过基于 KV 缓存统计特性的自定义张量编码器和自适应流式传输机制，将 KV 缓存体积压缩 3.5-4.3x，并将首个 Token 生成延迟 (TTFT) 降低了 3.2-3.7x 。

KVFetcher: Efficient Remote Prefix Fetching with GPU-native Media ASICs	arXiv	2026	此处为语雀内容卡片，点击链接查看：https://www.yuque.com/linlin-sami1/sm6gb7/yyp42zvhtcc9eiwt?view=doc_embed	本研究提出了 KVFetcher，这是首个利用现代 GPU 中闲置的专用视频编解码硬件 (Media ASICs) 来加速大语言模型 (LLM) 远程 KV Cache 获取的系统。通过设计编解码器友好的张量布局 (Codec-friendly Tensor Layout) 和自适应分辨率的获取管道，该系统在受限带宽环境下实现了高达 3.51 倍的首字延迟 (TTFT) 降低，且不占用 CUDA 核心资源，保证了推理过程的精度无损与干扰隔离。